

```
In [1]: from numpy.linalg import inv, eigvals
import numpy as np
```

1. Współczynnik uwarunkowania macierzy

```
In [2]: def cond_matrix(A, norm) -> float:
return norm(A) * norm(inv(A))
```

2. Norma macierzowa M1

Można ją również wyliczyć równoznacznie:

```
In [3]: A1 = [[1,2,3],
             [3,5,33],
             [8,9,6],]

def m1_norm(A) -> float:
    num_columns = len(A[0])
    column_sums = [0] * num_columns

    for row in A:
        for i in range(num_columns):
            column_sums[i] += row[i]

    return max(column_sums)

print("Norma M1 dla macierzy A1: {:.2f}".format(m1_norm(A1)))
print(f"Współczynnik uwarunkowania macierzy A1 z normą M1: {cond_matrix(A1, m1_norm)}")
```

Norma M1 dla macierzy A1: 42.00
Współczynnik uwarunkowania macierzy A1 z normą M1: 5.870967741935485

2. Norma macierzowa M2

Można ją również wyliczyć:

```
In [4]: A2 = [
             [11,23,2],
             [7,5,7],
             [8,6,6],
             ]

def m2_norm(A) -> float:
    eigenvalues, eigenvectors = np.linalg.eig(A)
    return max(eigenvalues)

print("Norma M2 dla macierzy A2: {:.2f}".format(m2_norm(A2)))
print(f"Współczynnik uwarunkowania macierzy A2 z normą M2: {cond_matrix(A2, m2_norm)}")
```

Norma M2 dla macierzy A2: 25.03+0.00j
Współczynnik uwarunkowania macierzy A2 z normą M2: (1.00000000000001+0j)

3. Norma macierzowa M inf

Można ją również wyliczyć:

```
In [5]: A3 = [
             [7,1,2],
             [3,0,8],
             [13,1,1],
             ]

def minf_norm(A) -> float:
    row_sums = []
    for row in A:
        row_sums.append(sum(row))

    return max(row_sums)

print("Norma Minf dla macierzy A3: {:.2f}".format(minf_norm(A3)))
print(f"Współczynnik uwarunkowania macierzy A3 z normą Minf: {cond_matrix(A3, minf_norm)}")
```

Norma Minf dla macierzy A3: 15.00
Współczynnik uwarunkowania macierzy A3 z normą Minf: 9.411764705882353

4. Norma macierzowa M p

???

5. Rozkład SVD dla macierzy

Postać rozkładu SVD:

gdzie: U - macierz wektorów własnych AA.T V - macierz wektorów własnych A.TA Sigma - macierz która na przekątnej ma pierwiastki wartości własnych macierzy AA.T

```
In [6]: def svd_eigen(A):
# Oblicz macierz A^T A
ATA = np.dot(A.T, A)

# Oblicz wartości własne i wektory własne macierzy A^T A
eigenvalues, eigenvectors = np.linalg.eig(ATA)

# Sortowanie malejące wartości własnych i wektorów własnych
idx = eigenvalues.argsort()[::-1]
eigenvalues = eigenvalues[idx]
eigenvectors = eigenvectors[:,idx]

# Macierz V - prawych wektorów własnych
V = eigenvectors

# Macierz Sigma - diagonalna macierz wartości osobliwych
Sigma = np.diag(np.sqrt(eigenvalues))

# Macierz U - lewych wektorów własnych
# Ze wzoru A = USVT wyznaczamy U: U = A * V * Sigma(-1)
U = np.dot(A, np.dot(V, np.linalg.inv(Sigma)))

return U, Sigma, V.T

# Przykładowa macierz A
A = np.array([[1, 2, 3], [2, 0, 7], [4, 5, 6]])

# Oblicz SVD
U, Sigma, VT = svd_eigen(A)
print("Macierz U:")
print(U)
print("\nMacierz Sigma:")
print(Sigma)
print("\nMacierz V^T:")
print(VT)
print()
print("Rekonstrukcja macierzy U*Sigma*V.T :")
print(U @ Sigma @ VT)
```

Macierz U:

```
[[ 0.32192765 -0.11663948 -0.93955192]
 [ 0.58234916  0.80684247  0.09937142]
 [ 0.74647977 -0.57913768  0.32766981]]
```

Macierz Sigma:

```
[[11.39327489  0.          0.          ]
 [ 0.          3.71293842  0.          ]
 [ 0.          0.          0.63825973]]
```

Macierz V^T:

```
[[ 0.39256009  0.38410854  0.83567769]
 [-0.22071609 -0.84271997  0.49192694]
 [ 0.89284992 -0.37720509 -0.24603929]]
```

Rekonstrukcja macierzy U*Sigma*V.T :

```
[[ 1.00000000e+00  2.00000000e+00  3.00000000e+00]
 [ 2.00000000e+00 -1.44554742e-15  7.00000000e+00]
 [ 4.00000000e+00  5.00000000e+00  6.00000000e+00]]
```

